严格时间切分下的 CTR 预测

最终中文报告 · 冻结证据与发布审计

研究范围：淘宝展示广告 26,557,961 条曝光。

摘要：

- F3 已完成日点击反馈使 LR test AUC 提升 +0.05070（F12 0.601790 → F123 0.652489），F2 为 +0.00630。

- 相同 F123 预算下，冻结 LR 为 0.652489，DeepFM 为 0.645933。对已保存预测做配对用户 cluster bootstrap：LR − DeepFM AUC +0.00655565，95% CI [+0.00596489, +0.00721123]，Holm p = 0.001998。四个模型之间所有 GAUC 差值的区间都含零。

- 过去点击广告的 category 序列（L=20，test 平均 4.69 个保留 token，30.21% 曝光为空历史）相对 zero 参照提升 AUC +0.000330，95% CI [+0.000216, +0.000440]。

- 在这种短而稀疏的点击 category 序列上，target attention 相对 mean pooling 没有稳定的排序优势（attention − mean AUC −0.0000086，区间含零）。

- Mean matched 校准后整体 COPC 0.986，双冷启动 0.581，即预测点击约比实际点击高 72%。

- 新增 F5 预算改用 behavior_log（L=200），每条 test 曝光保留 185.19 个 token、空历史仅 0.435%。冻结 test 上相对 pipeline null 提升 +0.00127246 AUC，95% CI [+0.00104340, +0.00150052]，Holm p = 0.003996；相对 F4 点击来源提升 +0.00094211 AUC。在已实现错配对照下，matched−mismatched 约占 matched−zero AUC 差值的 95%，是描述性比例，不是身份因果贡献。Mean 对 zero/F4 的 GAUC 区间含零；attention 三项次比较有未经 GAUC 指标族多重校正的名义探索性证据。

- 在 F5 更丰富的序列源上，attention 首次与 mean pooling 分离（+0.00023967 AUC，区间排除零），但效应量约为matched−mismatched 差值的五分之一、约两个 seed 标准差；mean matched 仍为预先选定的主模型。

- F5 的内存 prepare + inference 吞吐为其所依附 DeepFM backbone 的 1/3.27（379,078 对 1,239,580 rows/s，batch 8192），即单行计算成本约 3.27 倍；峰值内存为 7.48 倍（6,082 对 813 MiB）。该内存来自 723,113,323 条事件常驻，不是残差的 57,345 个参数。

核心结论：在本项目的数据口径、信息层与调参预算下，高质量历史点击反馈带来的增益，大于所观察到的模型复杂度增益。用户匹配的过去点击广告 category 序列提供小幅增量；在该表示上 target attention 未显示优于简单均值聚合的稳健实际优势。上述序列结论仅限于点击广告 category 这一来源，不推广到完整 behavior_log 的 pv/cart/fav/buy 行为序列，也不构成对序列建模或 DIN 的一般结论。 序列模型未超过强全局 LR 基线，但用户内排序呈现不同结论。

数据切分与指标口径

数据分区	北京时间日期	曝光数	用途
Train	2017-05-06 至 05-11	20,015,245	词表、标准化、训练
Validation	2017-05-12	3,234,051	配置与校准方法选择
Test	2017-05-13	3,308,665	冻结最终报告，166,490 次点击

指标方向：AUC、PR-AUC、GAUC 越高越好；LogLoss、Brier、ECE 越低越好。COPC = 实际点击数 / 预测点击数 = CTR / 平均预测；理想值为 1，小于 1 表示高估，大于 1 表示低估。COPC 增大本身不等于改善。COPC=0.581 表示预测点击比实际点击约高 72%（1/0.581 − 1）；它与「实际比预测少 42%」（1 − 0.581）是分母不同的两个量，不可混用。

GAUC 按用户曝光量加权，仅包括同时具有正负样本的用户：test 合格用户 104,884 个，覆盖 1,682,247 次曝光（50.84%）。来源：[R1–R3]。

00 · F5 行为序列预算与一次性正式 test

F5 是第二个序列来源，在正式 pass 之前已提交全部分析规则，仅执行一次推理。F4 保留平均 4.69 个点击广告 category token、30.21% 的 test 曝光为空；F5 保留 185.19 个 behavior_log token、空历史 0.435%。两者共用同一个冻结 DeepFM backbone。

条件	Test AUC ± std	Test LogLoss ± std	Test GAUC ± std
F5 attention matched	0.647445 ± 7.7e-5	0.193043 ± 2.9e-5	0.570476 ± 5.4e-5
F5 mean matched	0.647206 ± 6.0e-5	0.193061 ± 3.1e-5	0.570251 ± 2.4e-4
F4 mean matched	0.646263 ± 4.4e-5	0.193120 ± 4.0e-6	0.570380 ± 1.1e-4
F5 mean mismatched	0.646003 ± 1.3e-4	0.193153 ± 1.1e-5	0.569840 ± 6.3e-5
zero pipeline null	0.645933 ± 0	0.193176 ± 0	0.569902 ± 0

两个主比较在 Holm p = 0.003996 下都排除零：mean matched − zero AUC +0.00127246 CI [+0.00104340, +0.00150052]；mean matched − mismatched AUC +0.00120269 CI [+0.00098519, +0.00142260]。错配保留约 5.5% 的 AUC 差值；matched−mismatched 占比约 95% 是已实现对照下的描述性比例，不能解释为用户身份的因果贡献，也未排除活跃度、新近度与热门度混杂。全部 12 组 AUC/LogLoss 配对在三个 seed 上方向一致。

三点限定。全局与用户内排序不一致：F5 mean 在 AUC 上同时超过 null 和 F4，但对二者的 GAUC 区间都含零（p = 0.172 与 p = 0.621）。增益落在稀疏来源为空的地方：在 985,688 条没有点击历史的曝光上 F5 − zero 为 +0.001607，高于两边都有历史时的 +0.001163；而在双冷启动上为负（28,331 行，−0.001741，无区间）。已保存的 bucket relaxation 排除敏感性较小：排除全部 1,457 行放宽样本后，matched − mismatched 在 AUC 上最多变化 9.0e-7，符号全部保持。

F5 将 LR F123（0.652489）与冻结 null 之间的全局 AUC 差距缩小约 19.4%，LR 仍领先约四倍于整个 F5 效应。GAUC 上次序反转：F5 为 0.570251，LR 为 0.569939——与冻结表格模型 bootstrap 一致（那里所有 GAUC 差值区间也都含零）。

校准沿用仅在 validation 选定的方法，13 个校准器全部选择 isotonic：mean matched 的 LogLoss 由 0.193061 降到 0.192755、ECE 由 0.004785 降到 0.000975、COPC 由 0.9478 升到 0.9866，AUC/GAUC 轻微下降（并列生成机制）。

详见 docs/F5_BEHAVIOR_VALIDATION.md、docs/F5_BEHAVIOR_TEST_RESULTS.md、docs/SERVING_BENCHMARK.md、docs/EXPERIMENT_INDEX.md。

00a · F5 donor 唯一性审计与结论边界

冻结实现是确定性的不同用户 donor 分配，带约 0.08% 用户级 reuse excess；不是严格一一置换。独立只读审计覆盖 05-06 至 05-13 的全部已保存映射，不重建数据、不训练、不推理。用户统计包含当日没有曝光的历史用户；曝光占比分母包含空历史。

指标	Validation 05-12	Test 05-13
有历史 target / assignment / eligible donor	1,131,745	1,134,206
distinct donor（唯一率）	1,130,861（99.921891%）	1,133,289（99.919150%）
reuse excess / 未用 eligible donor	884（0.078109%）	917（0.080850%）
被复用 donor / 最大 indegree	869 / 4	911 / 3
分配到重复 donor 的 target / 当日有曝光者	1,753 / 575	1,828 / 562
对应曝光 / 全日曝光占比	15,389 / 0.475843%	12,845 / 0.388223%

reuse excess = assignments − distinct donors；涉及的 target 包含重复 donor 的首次使用者，不能把该比例与曝光覆盖混用。全部日期 self-match、长度错配、未来事件、ownership 与顺序违规均为零。约 0.08% 不自动证明指标影响可忽略；没有重训严格 derangement 版本，无法给出其反事实指标。

Validation 的曝光加权 category TV 为 0.04982，事件年龄 3.75 vs 4.08 天，过去活跃度 138.23 vs 87.72。保留长度精确一致，粗 activity/recency bucket 几乎匹配，但用户级近似平衡不等于曝光级平衡。活跃度差是曝光加权与粗分桶下的残余不平衡，不能简单归因于 donor 复用；后者是额外限制。原排除 1,457 条 bucket 放宽曝光的分析也没有量化 donor 复用的指标影响。

Mean matched−mismatched 约占 matched−zero AUC 差值 95%，只是在当前对照下的描述性比率，不是身份因果贡献。Mean 对 zero/F4 的 GAUC 区间含零；attention−zero、attention−attention mismatched、attention−mean 的 GAUC 区间排除零，但属于未经 GAUC 指标族多重校正的名义探索性证据。

完整 8 日统计、indegree 分布、分桶表及审计方法：docs/F5_DONOR_UNIQUENESS_AUDIT.md；results/f5_donor_uniqueness_audit_v1/。小型汇总复算入口：src/58_audit_e1_e6_release.py。此审计不验证因果结论。

01 · 最终实验清单与时间语义

阶段	已完成内容	证据与边界
数据与信息层	F1 静态上下文；F2 行为统计；F3 历史反馈	raw ID 先连接；词表与标准化仅由 train 拟合
四类表格模型	LR、LightGBM、Wide & Deep、DeepFM	各一个冻结 seed 42；不补做独立 backbone 多种子
F4 序列机制实验	mean / attention × matched / mismatched	三个残差 seed：42、2026、3407；共享一个冻结 DeepFM
零序列参照	同管线硬零表示	一个确定性预测器；三次引用不等于三个独立模型
统计与校准	五组比较；1,000 次用户 cluster bootstrap；13 个校准器	已完成并冻结于 badecf4；本次不重算、不重拟合
D2 / D3 / D4	保存预测的分组诊断 / validation 敏感性 / 描述性时序	无新正式模型，无新 test 推理
D5 / release	统一报告、八幅图、数值与交付审计	只整理冻结证据；项目扩展停止

行为日志的有效窗口为 2017-04-22 至 05-13 共 22 天，承载全部事件的 99.9786%；更早的时间戳零散或损坏（653 个日期共 127,136 条），因此 05-06 之前的有效历史为 14 个完整日。F3 在训练首日 05-06 没有窗口内的已完成前日，全部实体历史退化为固定 prior 且 has_past_feedback = 0；这 3,270,348 条曝光（训练集 16.3%）予以保留，未被删除。

F4 是过去正点击广告的 category 有序序列，初始及冻结长度 L=20。曝光日 D 只使用北京时间日期严格小于 D 的正点击记录，不使用同日点击。曝光 timestamp 是正点击记录时间的代理，假设反馈次日可用；数据没有独立点击发生时间。Validation 不含 05-12 点击，test 可以使用已经结束的 05-12 点击。

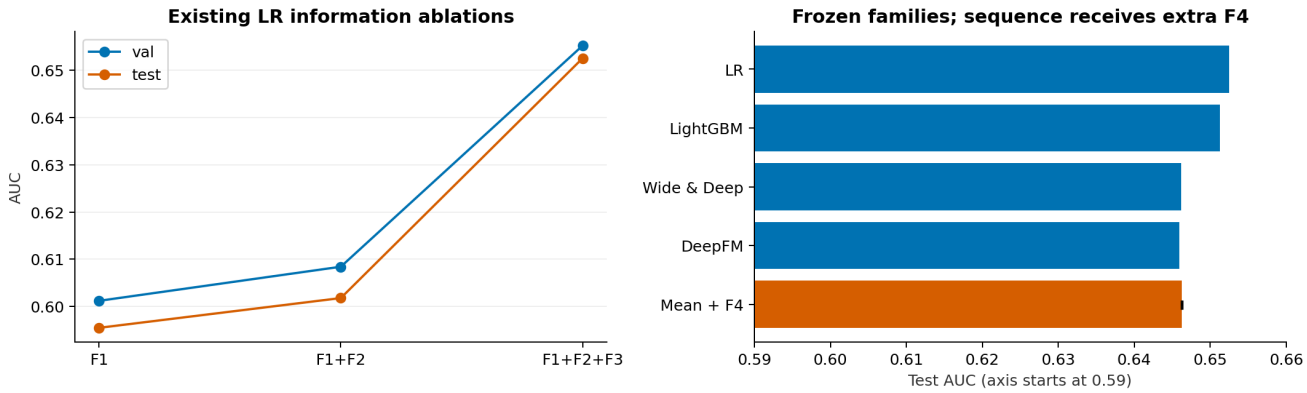
序列词表只由 train 建立；PAD=0、UNKNOWN=1 为中性零向量，空历史得到严格零序列表示。错配以 cutoff、保留长度和过去活跃度分桶确定性置换，seed=20260926。序列残差配置 LR=5e-4、batch=4096、L=20、epoch=1；原 backbone 不重训。来源：[R1–R3]。

02 · 信息增益与模型复杂度

表 1 | 原始 test 指标。序列行是三个残差 seed 的均值 ± 样本标准差（ddof=1），不是概率平均集成；其余为单个冻结 seed。

模型 / 信息层	AUC ↑	LogLoss ↓	GAUC ↑
LR F1	0.595495	0.196781	0.561913
LR F12	0.601790	0.196376	0.561534
LR F123	0.652489	0.192429	0.569939
LightGBM F123	0.651318	0.192502	0.569889
Wide & Deep F123	0.646219	0.193161	0.569680
DeepFM F123 / zero	0.645933	0.193176	0.569902
Mean matched F123+F4	0.646263 ± 0.000044	0.193120 ± 0.000004	0.570380 ± 0.000108

Information gain exceeds observed model-complexity gain



Tabular models: one frozen seed each. Sequence: residual-seed mean ± std on one shared backbone; not a pure architecture comparison.

图 1 | 已有 LR 信息层对照与冻结模型。右图横轴起点 0.59；序列增加 F4，不是纯架构对照。

F3 的 LR AUC 增量约 0.05070，F2 约 0.00630。原 LR 选择 epoch 分别为 3、3、2；不能解释为完全相同固定 epoch 的因果对照。

02a · 已冻结表格模型的用户抽样区间

对已保存 test 预测的配对用户 cluster bootstrap（1,000 次，seed 20260926，协议预先提交于 29659c3）为表格模型排序给出区间：

比较	指标	点估计	95% CI	区间是否排除零
LR − DeepFM（主）	AUC	+0.00655565	[+0.00596489, +0.00721123]	是
LR − DeepFM（主）	LogLoss	−0.00074793	[−0.00083617, −0.00067152]	是
LR − LightGBM	AUC	+0.00117059	[+0.00059116, +0.00173101]	是
LR − LightGBM	LogLoss	−0.00007366	[−0.00014903, +0.00000767]	否
LR − LightGBM	GAUC	+0.00004970	[−0.00124507, +0.00127498]	否
LR − Wide & Deep	GAUC	+0.00025893	[−0.00079951, +0.00140635]	否

Holm 只覆盖两个主指标（均为 p = 0.001998）。区间以四个冻结模型与这一个 test 日为条件，刻画用户抽样不确定性，不是训练 seed 不确定性——每个表格模型只有一个 seed。两点对叙述重要：LR 的全局排序优势在用户重抽样下稳定，而所有 GAUC 差值区间都含零，说明该优势没有转化为用户内排序优势；LR 相对 LightGBM 是排序差异，不是概率质量差异。来源：[R2、R3、R7]、docs/FROZEN_MODEL_BOOTSTRAP.md。

03 · 五组预先冻结比较

表 2 | 左模型减右模型。AUC 为正、LogLoss 为负代表左侧较好；secondary 仅为机制性 / 探索性比较。

顺序	冻结比较	ΔAUC	ΔLogLoss
Primary 1	Mean matched − zero	+0.000330347	−0.000056164
Primary 2	Mean matched − mean mismatched	+0.000405708	−0.000030542
Secondary 3	Attention matched − zero	+0.000321725	−0.000058000
Secondary 4	Attention matched − attention mismatched	+0.000397302	−0.000032132
Secondary 5	Attention matched − Mean matched	−0.000008622	−0.000001836

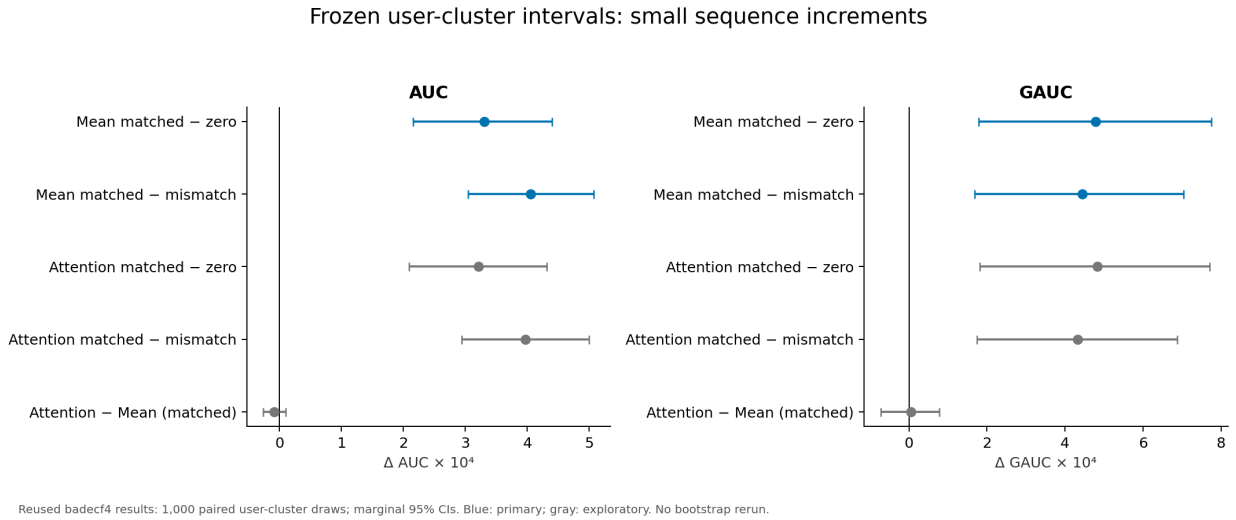


图 2 | 已有用户 cluster bootstrap 的 95% 边际区间；横轴效应乘以 10⁴。蓝色为 primary，灰色为探索性比较。

原 bootstrap seed=20260927，共 1,000 次有效重复；整用户曝光一起抽样。两个 primary 的 AUC/LogLoss 在联合四假设 Holm 下 p=0.003996。三个残差 seed 的 matched−mismatched 在四项指标上方向一致。区间是给定模型与日期的数据抽样不确定性，seed 标准差是固定 backbone 下的训练随机性；两者不同。来源：[R1、R2]。

04 · 增量很小，用户内排序与全局排序不同

Mean matched − zero 的 ΔAUC=+0.000330347，已有 95% CI 为 [+0.000215737, +0.000440027]。Mean matched − mismatched 的 ΔAUC=+0.000405708，已有 CI 为 [+0.000304701, +0.000507655]。它们分别约为 0.0330 和 0.0406 个 AUC 百分点；LogLoss 相对改善仅约 0.0291% 和 0.0158%。统计可检测不等于实际增益很大。

Attention − mean 的 AUC、PR-AUC、GAUC 区间含零；LogLoss 百分位区间略低于零，但预先定义的 centered p=0.064935。两种统计量并非互为反演，原样保留，不能择优引用。Mean 仍为主要序列模型。

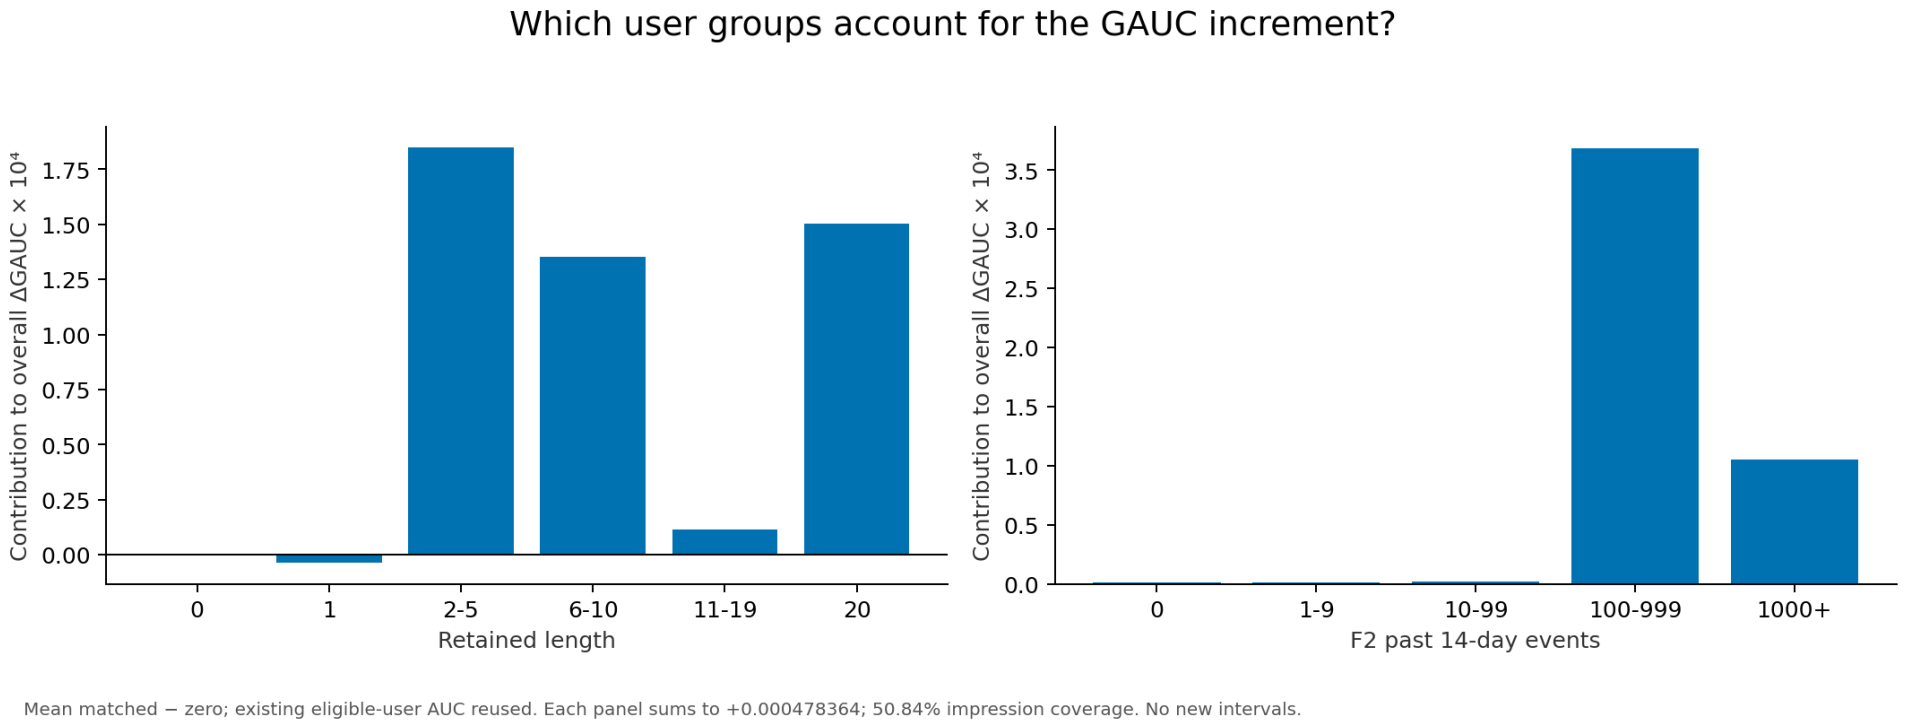


图 3 | Mean matched − zero 的 GAUC 加性贡献；各面板加总均为 +0.000478364。分组贡献包含组大小和组内效应。

约 98.89% 的 GAUC 增量来自已知用户；长度 2–5、6–10、20 贡献主要增益，长度 1 略为负，空历史严格为零。活跃度 100–999 和 1000+ 分别贡献约 77.02%、22.05%。但所有固定活跃度分桶的全局 AUC 仍是 LR 更高；这些是描述性分解，没有新增分组显著性检验。来源：[R1、R4]。

05 · 长历史：为何 AUC 改善而 LogLoss 恶化

在保留长度 20 的组中，Mean matched − mismatched 的 ΔAUC=+0.000474273，ΔLogLoss=+0.000019789。排序改善与概率误差变差可以同时成立：非点击样本增加的损失约 +0.000615，略超过点击样本改善的约 −0.000595。原始历史长度 ≥50 的样本贡献了净损失恶化的 58.64%。

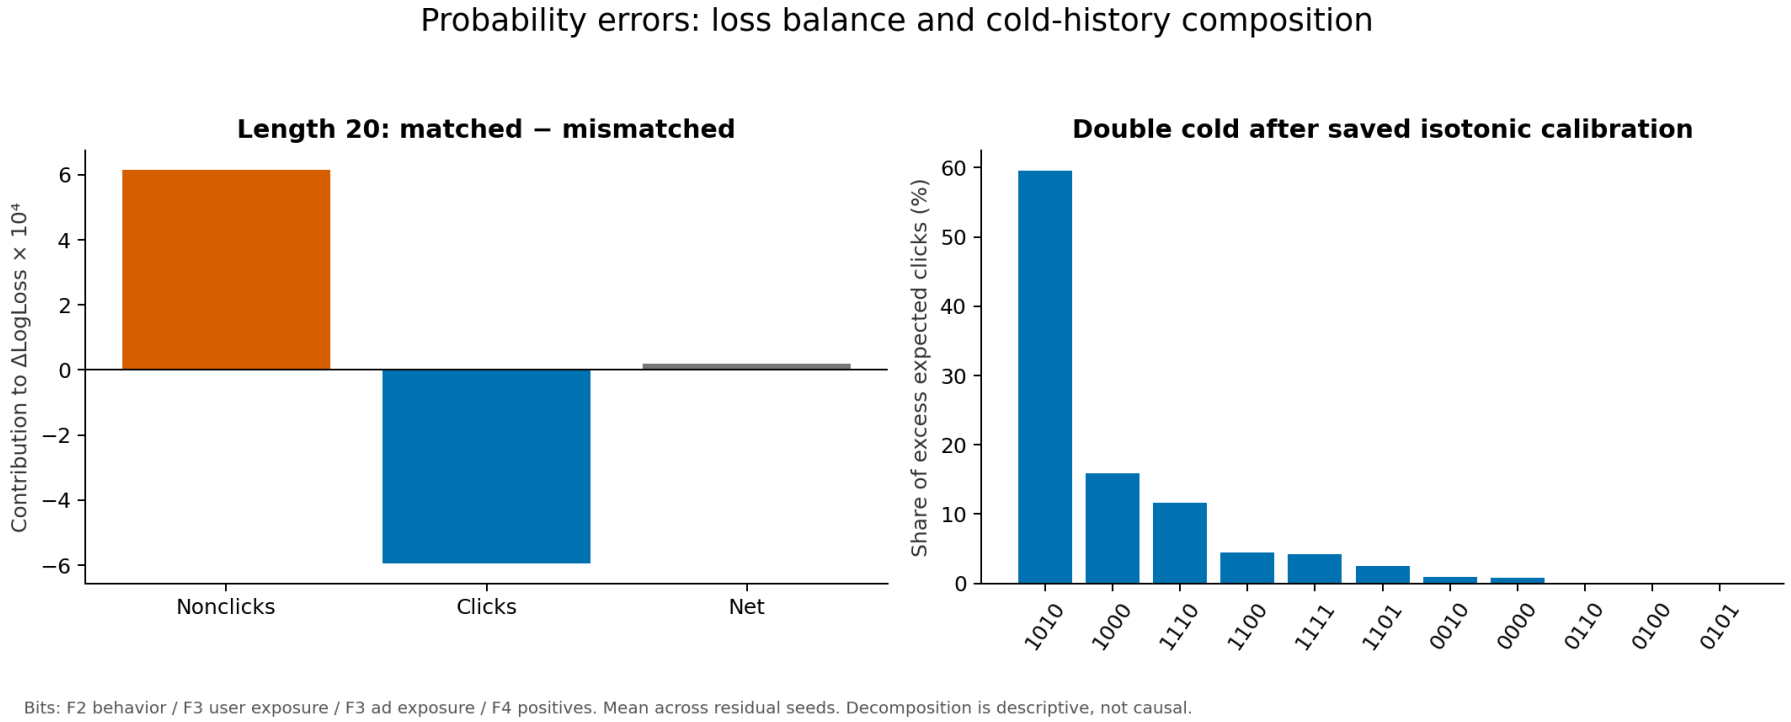


图 4 | 左：长度 20 组的标签分解，纵轴为 ΔLogLoss ×10⁴；右：校准后双冷启动过量预测点击的构成。

“20”表示达到截断上限，包含原始长度等于及大于 20。上述分解解释损失的加总关系，并不识别截断的因果效果；该组 matched 相对 zero 的 LogLoss 仍更好。

右图四位证据码依次表示：F2 行为、F3 用户曝光、F3 广告曝光、F4 正点击历史是否存在。1010 组贡献约 59.54% 的过量预测；0000 组只贡献约 0.82%。用户 / 广告不在 train 词表，仍可能具有随后积累的历史证据，“冷启动”不等于“完全空历史”。来源：[R4]。

06 · 全局校准改善，不代表冷启动偏差消失

校准只在 validation 拟合与选择：按 impression_id 哈希进行约 80% 拟合、20% 方法选择，再在完整 validation 重拟合所选方法。四个序列条件各三个 seed、zero 一次，共 13 个校准器，均选择 isotonic。完整 validation 上的校准后指标属于拟合内指标，不是独立验证。

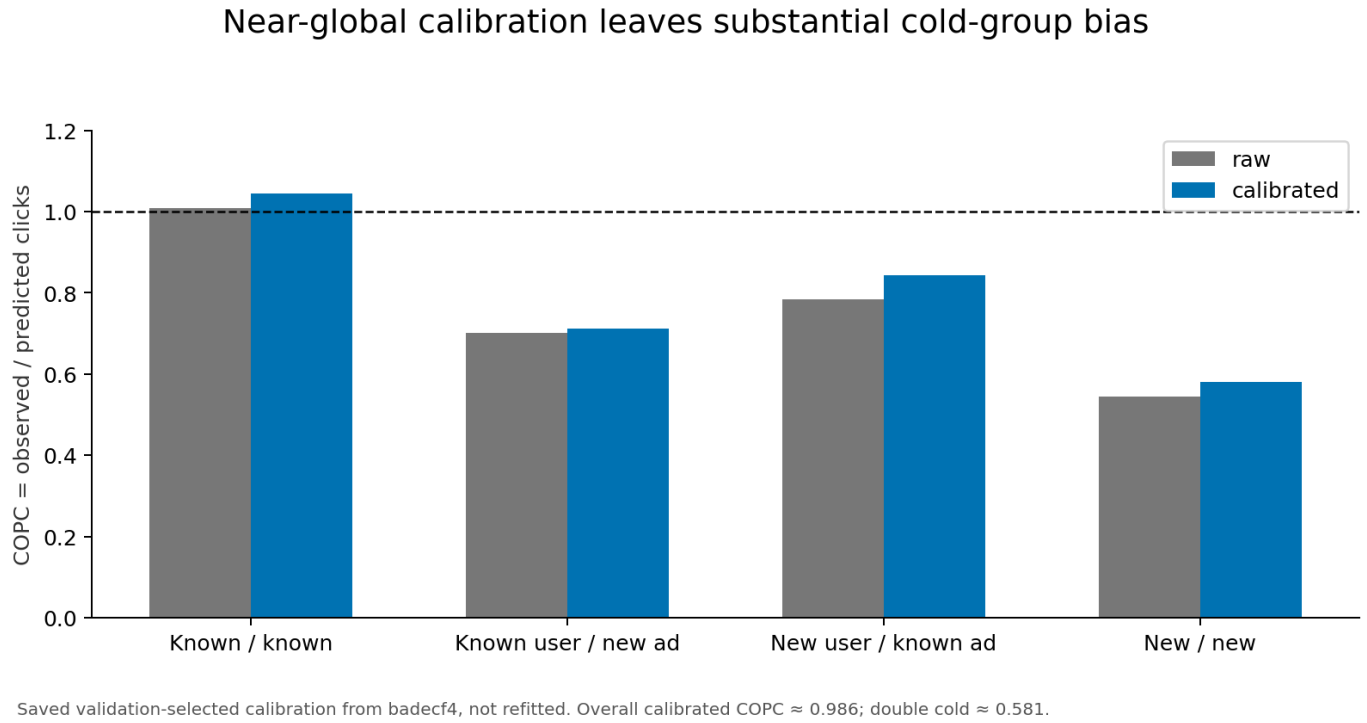


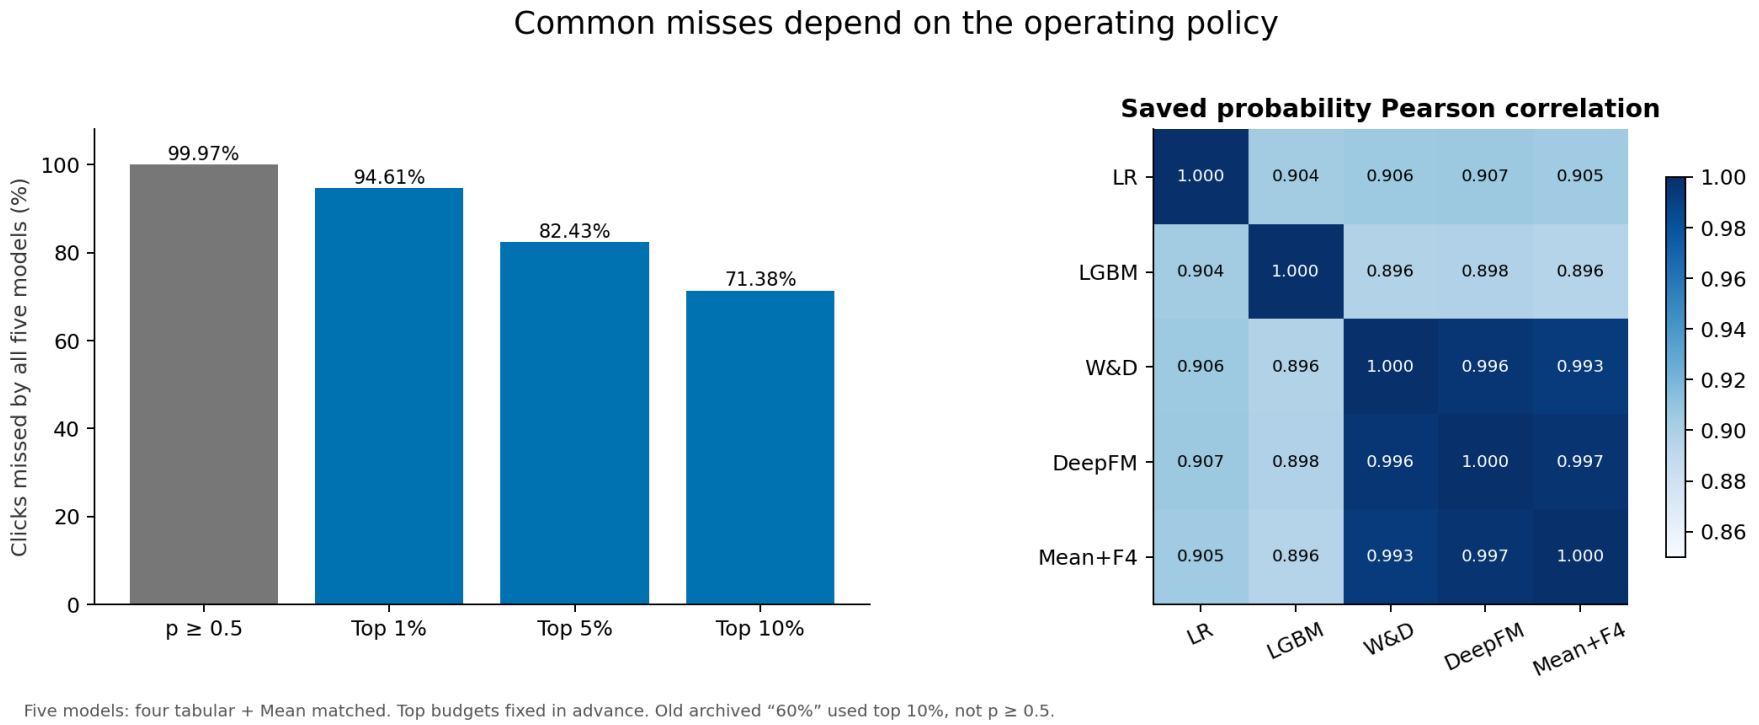
图 5 | 已有校准前后冷启动 COPC；虚线 1 为理想值，低于 1 表示高估。校准器与图表均直接复用冻结产物。

Mean matched 的 test 校准后 LogLoss=0.192839887、ECE=0.001043477、COPC=0.986346；双冷启动 COPC 却只有约 0.581043，对应 28,331 条曝光中 1,024 次点击，而预测约 1,762 次。已知用户 / 已知广告组 COPC 从约 1.009267 升到 1.043399，偏差方向与改善程度并不一致。

全部 13 个预测器的整体 LogLoss/ECE 改善，但 AUC、PR-AUC、GAUC 均下降；isotonic 引入的并列可改变排序指标。共享 evaluator 的 ECE 为 10 个等频箱；校准选择历史辅助输出采用 20 个等宽箱，不能混作同一指标口径。未使用 test 决定是否保留校准器。来源：[R1、R4]。

07 · 共同漏报与模型互补性的审计

五模型是 LR、LightGBM、Wide & Deep、DeepFM 和 Mean matched。在每个模型各自 top-10% 曝光预算下，71.38% 的真实点击被五者共同漏掉；分母为全部 test 点击，而不是全部曝光。使用 probability≥0.5 时，共同漏报约 99.97%，不能混用这两种操作策略。



Five models: four tabular + Mean matched. Top budgets fixed in advance. Old archived “60%” used top 10%, not p ≥ 0.5.

图 6 | 共同漏报随曝光预算变化；右图为已保存概率的 Pearson 相关。Top 10% 列对应每模型 top-10% 曝光预算下的 71.38% 共同漏报。

旧“60%”代码本来采用 top-10% 分位阈值，并非 probability≥0.5。旧预测数组缺失，且旧脚本会跳过缺失模型、缺少 ID 对齐断言，因此无法精确复现旧 60%；不能将其与重建后的 330.9 万 test 曝光结果合并。

每模型 top-10% 集合的并集覆盖 14.61% 曝光、召回 28.62% 点击，不是相同预算下的集成收益。Mean matched 与 DeepFM 的概率 Pearson 约 0.99734。使用真实标签逐行挑选最低损失的 oracle LogLoss 约 0.178235，是不可部署的乐观界，不是已实现的集成效果。来源：[R4、R8]。

08 · 冻结组件删除：敏感性诊断

D3 仅使用 05-12 validation。Frozen component deletion 明确属于 sensitivity diagnostic（敏感性诊断），不是 retrained ablation（重新训练的消融）。参数保持固定，特征中和或 logit 分支删除可能造成分布外输入；不能将剩余分支当作独立训练的模型。

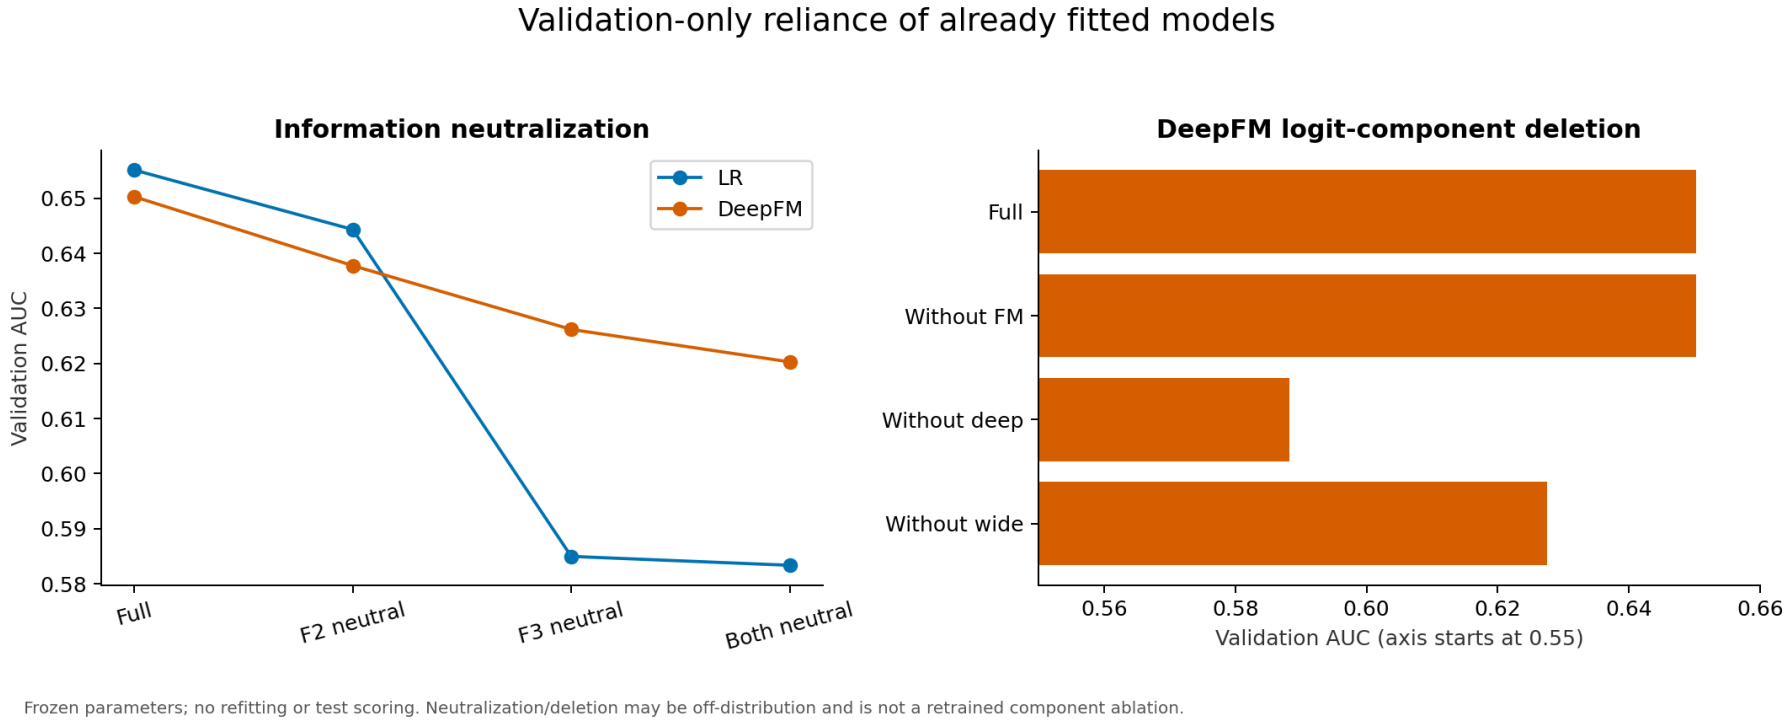


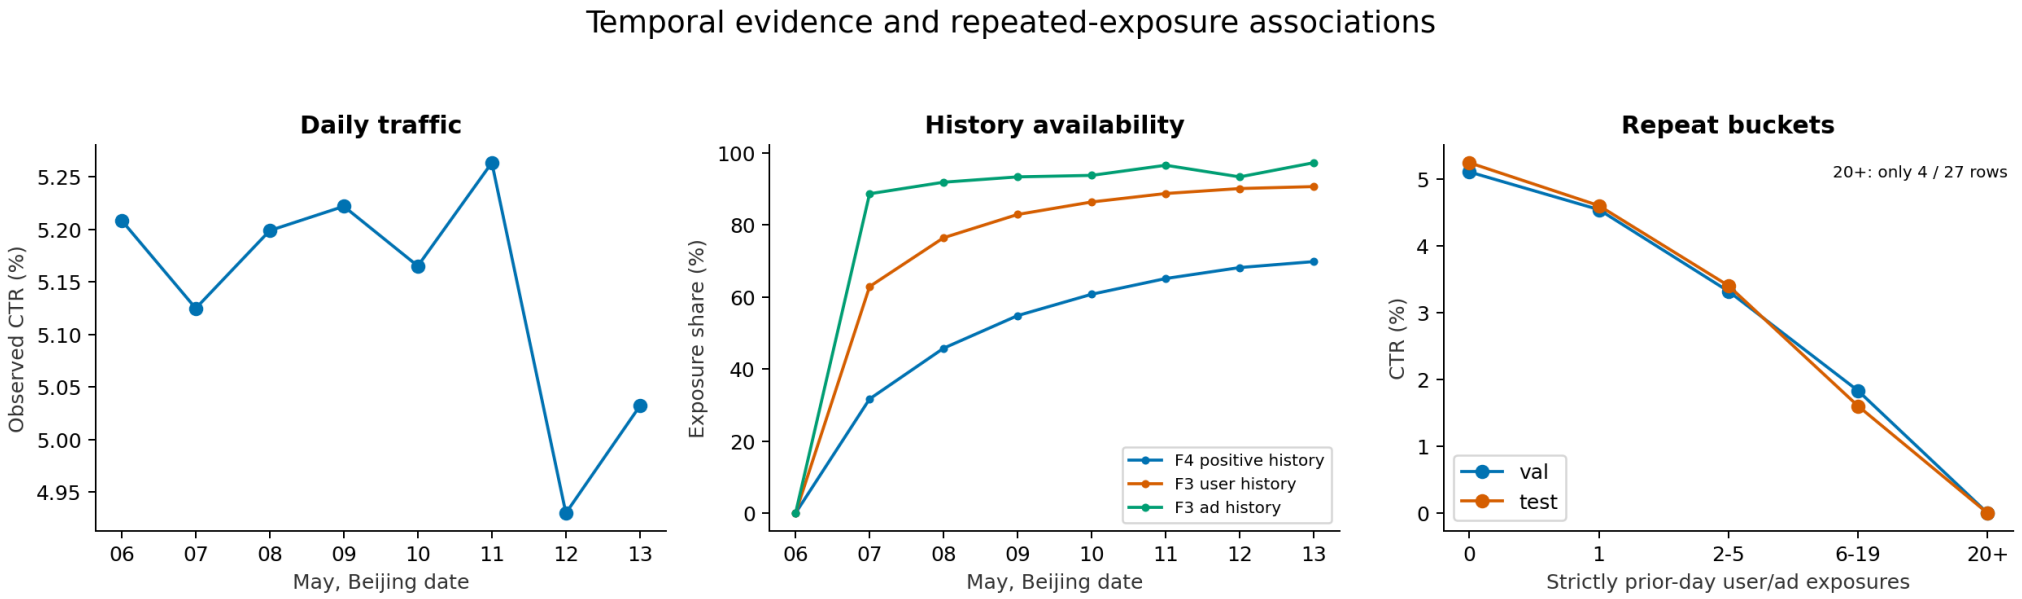
图 7 | Validation-only sensitivity diagnostic；左为冻结模型的 F2/F3 中和，右为冻结 DeepFM logit 分支删除，横轴起点 0.55。不是 retrained ablation。

LR 的 validation AUC：完整 0.655163，中和 F2 为 0.644353，中和 F3 为 0.584946；DeepFM 对应 0.650315、0.637786、0.626190。两者均更依赖已有 F3。

删除 DeepFM 的 FM 项后 AUC 仅从 0.650315 变为 0.650292，而 LogLoss 从 0.189813 变为 0.190702，说明排序与概率水平变化不能互相替代。LR 的 F2 加性项在同一 validation 日的同用户内恒定，因此删除 F2 可改变全局 AUC，而不改变用户内排序。现有 epoch 曲线记录过拟合迹象，但不能证明模型复杂度普遍有害。来源：[R5]。

09 · 时间漂移与重复曝光：描述性关联

时间漂移与重复曝光结果均为描述性关联，不是因果估计。05-11、05-12、05-13 的 CTR 分别为 5.2633%、4.9299%、5.0319%，变化并不单调。Validation 到 test 的新用户占比从约 9.94% 升至 11.70%，新广告从 6.71% 升至 8.77%。



Descriptive dates, not rolling-origin model evaluation. More history partly reflects window accumulation. Repeat association does not establish fatigue.

图 8 | 每日 CTR、历史证据覆盖与重复曝光 CTR。左中图横轴为北京时间 5 月日期；右图重复次数严格来自曝光日之前。

历史广告证据覆盖从 93.29% 升至 97.22%，部分来自可观测窗口累积。三日滚动表只描述流量，并未执行 rolling-origin 模型评估，也没有把训练期预测当成 held-out 预测。

test 的历史 user/ad 重复曝光桶 0、1、2–5、6–19 的 CTR 约为 5.24%、4.60%、3.40%、1.60%。≥20 桶只有 27 条曝光且无点击，AUC 不可定义。曝光选择、幸存者偏差与左截断均存在，因此不能把较低 CTR 直接解释为广告疲劳。只有两个 held-out 日期，不支持稳定的跨时期泛化定律。来源：[R6]。

10 · 结论层次与证据限制

问题	当前证据允许的结论	不允许的延伸
历史信息是否重要	LR 信息层结果与冻结敏感性均支持 F3 的主要贡献	不能声称对所有模型与数据均成立
matched 是否优于 mismatched	五组冻结比较中的匹配收益小且可统计检测	不能解释为完全控制所有热门度 / 活跃度混杂
F4 序列是否超越 zero	对冻结 backbone 有小幅 AUC、LogLoss、GAUC 增益	不能声称三次独立 backbone 重训获胜
attention 是否超越 mean	在点击 category 序列上无稳健实际优势；mean 仍为主要序列模型	不因 test 结果更换优先级；不推广到 behavior_log 序列
序列结论的适用范围	F4 覆盖点击广告 category（平均 4.69 token）；F5 覆盖 behavior_log（平均 185.19 token）	不能读作对序列建模或 DIN 的一般否定
F5 是否超过 F4	全局 AUC 上超过（+0.00094211，区间排除零）	mean 比较的 GAUC 增益未获证实，区间含零
F5 增益是否值得部署	预算取舍：内存准备与推理吞吐降至 1/3.27（单行计算成本约 3.27 倍）、峰值内存 7.48 倍，换 +0.00127 AUC	内存来自事件存储常驻，不是残差参数；流式读取、内存映射、分层缓存或离线特征服务均可优化
全局与用户内排序	LR 全局强；Mean matched 的 GAUC 较高	不新增未冻结的显著性比较
校准与分组误差	整体概率误差改善，但双冷启动偏差保留	不声称分组校准已被验证有效

Test 在早期基线开发中已经被查看，后来才冻结，不是从未触碰的 holdout。bootstrap 与深挖方案是在已知整体 test 结果后、对应新分组结果前固定，不能追称为最初预注册。校准实际采用 impression-level 80/20，而非历史提案的 user-grouped OOF，偏离须保留。需要准确表述的是：校准器只接收预测概率与标签，从不接收 user_raw，因此不构成校准器记住用户标签的泄漏。真实局限是样本依赖——同一用户的曝光并非独立，按 impression 切分使拟合集与选择集相关，可能低估方法选择的不确定性。若要评估对全新用户的校准泛化，user-grouped 切分才是合适设计。

各表格模型只有一个 seed；三个序列 seed 只刻画共享冻结 backbone 下的残差随机性。未完成 LightGBM F1/F12、独立训练 FM/DNN 消融或三套独立表格 backbone。E6 已补充同机独立子进程 CPU 吞吐基准；这仍不是生产冷缓存 I/O 延迟测量。

冻结证据仍为 badecf4 及 DIN_F4_TEST_RESULTS.md。所有新增交付仅为已有数字的核验与呈现，不增加训练、推理、统计检验或 post-hoc 分析。来源：[R1、R7]。

09b · 如何阅读不确定性

三个量彼此独立，绝不混用。

1. bootstrap 区间以冻结模型及其已保存预测为条件。 它重抽样 test 用户，回答的是「这一差值在这一天换一批用户是否还成立」，不是训练随机性，也不回答「重新训练是否还成立」。

2. seed 标准差只刻画残差的训练随机性。 F4/F5 序列条件使用三个残差 seed（42、2026、3407），但共用同一个冻结 DeepFM backbone。四个表格模型各只有一个 seed，其排序完全没有训练随机性估计。

3. zero 对照的零标准差是结构性的。 它是共享 backbone 上的一个确定性预测器被评估三次，不是三个独立训练的模型，三次引用按构造完全相同。

由于所有序列条件共用一个 backbone，它们之间的任何对比都不是完整模型比较。

10a · F5 增益落在哪里、双口径工程结论与限制

效应为 F5 mean matched 减 zero null，原始概率，三 seed 平均。这些是描述性分组差异，无区间、无多重性控制；小格只给方向，不构成证据。

- 增益最大处正是稀疏来源为空之处：在 985,688 条无点击历史的曝光上（约占 test 日 29.8%），F5 − zero 为 +0.001607，高于两边都有历史时的 +0.001163。两个空历史格精确为 0，符合架构要求。

- 新用户 + 已知广告增益最大：+0.002785（358,678 行），行为历史部分替代了未见过的用户 ID。

- 双冷启动为负：−0.001741，但仅 28,331 行且无区间。只报告方向，刻意不作解释。

- 已保存的 bucket 放宽排除敏感性较小：仅涉及 1,457 行（0.0440%）；排除后 matched − mismatched 在 AUC 上最多变化 9.0e-7、GAUC 上 5.0e-6，符号全部保持。

- 高 UNKNOWN 组未观察到更小的 AUC 增益：零 UNKNOWN 时 +0.001113，>0.20 时 +0.001526。这里只能说明高 UNKNOWN 组没有观察到更小的 AUC 增益，不能判断移除 masking 的反事实效果。全事件库比例为 4.3029%，test matched 保留 token 为 3.941954%（24,153,874 / 612,738,660），分母不同。

工程口径必须两种同时报告，因为两者的差距会改变部署结论。LR 在 batch 8192 下纯模型吞吐 18,083,051 rows/s，内存 prepare + inference 仅 1,275,056，14.2 倍落差几乎全部来自构建 2,497,016 维稀疏行。只用纯模型数字得出的部署结论是错的：需要先优化的是特征构建，不是模型。F5 仅增加 57,345 参数，不代表计算可忽略：纯模型 @8192 吞吐 658,608 对 DeepFM 的 1,530,445 rows/s，为其 1/2.32；内存 prepare + inference 为 1/3.27，峰值 RSS 7.48 倍。7.23 亿事件常驻主导内存，计算同时来自 200-token 前向与序列准备。旧 CSV 的 end_to_end_* 只是历史字段名；计时排除 Parquet 打开、磁盘读取、解压和反序列化。尚未测量包含真实磁盘/Parquet I/O 的冷缓存在线服务延迟。

主要限制（刻意保留，未解决）：comparison 6 缺 F4/F5 分组差值分解（F4 参照只有整体指标）；LightGBM 节点数未统计（全量 dump 内存成本不合理）；表格模型单 seed，其排序未与训练随机性分离；F5 是冻结 DeepFM backbone 上的序列残差，不是联合训练的 DIN/DSIN 复现，公开 Alimama 中「引入行为序列」约 +0.0074 AUC 而 F5 为 +0.00127；completed-day cutoff 比事件级更保守，为与 F2/F3/F4 可比且不引入新的可用性假设而刻意保留；F5 的服务内存是本实现的产物，流式读取、内存映射、分层缓存或离线特征服务均可降低，6,082 MiB 不是预算下界；来源、长度与训练方式未被分别识别——F5 同时改变了序列来源、保留长度与 token schema，结果支持「序列来源与信息密度是 F4 效应较小的重要解释」，但没有单独识别各因素的因果贡献。

10b · 正式 test 推理次数与组成

正式 test 保存预测清单共 38 项，已对照 manifest、once-only marker 与冻结 registry 核实。F4/F5 marker 约束每个 checkpoint 一次推理；仅凭文件计数不能独立证明全部早期 LR 运行从未覆盖重跑：

来源	次数
F4 点击广告序列条件	15
F5 行为序列条件	15
LR 信息层（F1、F1+F2、F1+F2+F3）	3
表格基准模型（LightGBM、Wide & Deep、DeepFM，均 F123）	3
旧命名的早期 LR run（logistic_regression、logistic_regression_no_weekday）	2
合计	38

早前文案写作「38 次（F4 15 + F5 15）」，算术不成立。余下 8 次为表格基准模型与两个旧命名 LR run，每个目录各含恰好一个 test 预测文件。

11 · 复现入口与仓库内引用

从仓库根目录执行只读交付检查：python src/37_verify_frozen_delivery.py；python src/38_release_audit.py；python src/58_audit_e1_e6_release.py。完整合成数据测试：python -m unittest discover -s tests -v；格式检查：git diff --check。这些不是重跑实验的命令。

核心依赖与已测版本分别见 requirements.txt、requirements-tested.txt；图表环境见 requirements-plot.txt；中文 PDF 排版环境见 requirements-report.txt。PDF 排版与 CTR 环境隔离。生成命令、字体参数及数据目录说明见 docs/RELEASE_AUDIT.md。

引用	仓库内可定位证据（路径相对仓库根目录）
[R1]	docs/DIN_F4_TEST_RESULTS.md；results/sequence_posthoc_v1/
[R2]	results/sequence_selection_v2/；results/sequence_test_v2/
[R3]	results/lr_f1*/；results/lightgbm_f1_f2_f3/；results/wide_deep_f1_f2_f3/；results/deepfm_f1_f2_f3/
[R4]	docs/DEEP_DIVE_D2_RESULTS.md；results/deep_dive_d2_v1/
[R5]	docs/DEEP_DIVE_D3_RESULTS.md；results/deep_dive_d3_v1/
[R6]	docs/DEEP_DIVE_D4_RESULTS.md；results/deep_dive_d4_v1/
[R7]	docs/FINAL_REPORT.md；docs/DEEP_DIVE_RESEARCH_PLAN.md
[R8]	results/deep_dive_final_v1/legacy_notebook_corroboration.json；archive/v1-original 分支

图 1–8 来自 figures/deep_dive_v1/ 已有八幅图（按本报告叙事重排），来源哈希见 results/deep_dive_final_v1/figure_manifest.json。图内沿用英文变量名，中文图题说明分母、方向和解释边界，未重绘或修改实验数值。

大型原始数据、模型、预测与中间表保存在本地 Git-ignored 目录，没有被小型 manifest 备份。缺少这些本地产物时只能核对已提交的汇总，不能声称完整重现实验。历史审计位于 results/release_audit_v1/；本轮修订、逐页检查与测试日志位于 results/release_audit_v3/。项目在本次 release 后停止扩展。