严格时间切分下的 CTR 预测

最终中文报告 · 冻结证据与发布审计

研究范围：淘宝展示广告 26,557,961 条曝光。实验与深挖已经结束；本报告只整合保存的指标、统计区间、校准结果和图表，没有新增分析或推理。

核心结论：在本项目的数据口径、信息层与调参预算下，高质量历史点击反馈带来的增益，大于所观察到的模型复杂度增益。用户匹配的类别序列提供小幅增量；target attention 未显示优于简单均值聚合的稳健实际优势。序列模型未超过强全局 LR 基线，但用户内排序呈现不同结论。

数据分区	北京时间日期	曝光数	用途
Train	2017-05-06 至 05-11	20,015,245	词表、标准化、训练
Validation	2017-05-12	3,234,051	配置与校准方法选择
Test	2017-05-13	3,308,665	冻结最终报告，166,490 次点击

指标方向：AUC、PR-AUC、GAUC 越高越好；LogLoss、Brier、ECE 越低越好。COPC = 实际点击数 / 预测点击数 = CTR / 平均预测；理想值为 1，小于 1 表示高估，大于 1 表示低估。COPC 增大本身不等于改善。

GAUC 按用户曝光量加权，仅包括同时具有正负样本的用户：test 合格用户 104,884 个，覆盖 1,682,247 次曝光（50.84%）。来源：[R1–R3]。

01 · 最终实验清单与时间语义

阶段	已完成内容	证据与边界
数据与信息层	F1 静态上下文；F2 行为统计；F3 历史反馈	raw ID 先连接；词表与标准化仅由 train 拟合
四类表格模型	LR、LightGBM、Wide & Deep、DeepFM	各一个冻结 seed 42；不补做独立 backbone 多种子
F4 序列机制实验	mean / attention × matched / mismatched	三个残差 seed：42、2026、3407；共享一个冻结 DeepFM
零序列参照	同管线硬零表示	一个确定性预测器；三次引用不等于三个独立模型
统计与校准	五组比较；1,000 次用户 cluster bootstrap；13 个校准器	已完成并冻结于 badecf4；本次不重算、不重拟合
D2 / D3 / D4	保存预测的分组诊断 / validation 敏感性 / 描述性时序	无新正式模型，无新 test 推理
D5 / release	统一报告、八幅图、数值与交付审计	只整理冻结证据；项目扩展停止

F4 是过去正点击广告的 category 有序序列，初始及冻结长度 L=20。曝光日 D 只使用北京时间日期严格小于 D 的正点击记录，不使用同日点击。曝光 timestamp 是正点击记录时间的代理，假设反馈次日可用；数据没有独立点击发生时间。Validation 不含 05-12 点击，test 可以使用已经结束的 05-12 点击。

序列词表只由 train 建立；PAD=0、UNKNOWN=1 为中性零向量，空历史得到严格零序列表示。错配以 cutoff、保留长度和过去活跃度分桶确定性置换，seed=20260926。序列残差配置 LR=5e-4、batch=4096、L=20、epoch=1；原 backbone 不重训。来源：[R1–R3]。

02 · 信息增益与模型复杂度

表 1 | 原始 test 指标。序列行是三个残差 seed 的均值 ± 样本标准差（ddof=1），不是概率平均集成；其余为单个冻结 seed。

模型 / 信息层	AUC ↑	LogLoss ↓	GAUC ↑
LR F1	0.595495	0.196781	0.561913
LR F12	0.601790	0.196376	0.561534
LR F123	0.652489	0.192429	0.569939
LightGBM F123	0.651318	0.192502	0.569889
Wide & Deep F123	0.646219	0.193161	0.569680
DeepFM F123 / zero	0.645933	0.193176	0.569902
Mean matched F123+F4	0.646263 ± 0.000044	0.193120 ± 0.000004	0.570380 ± 0.000108

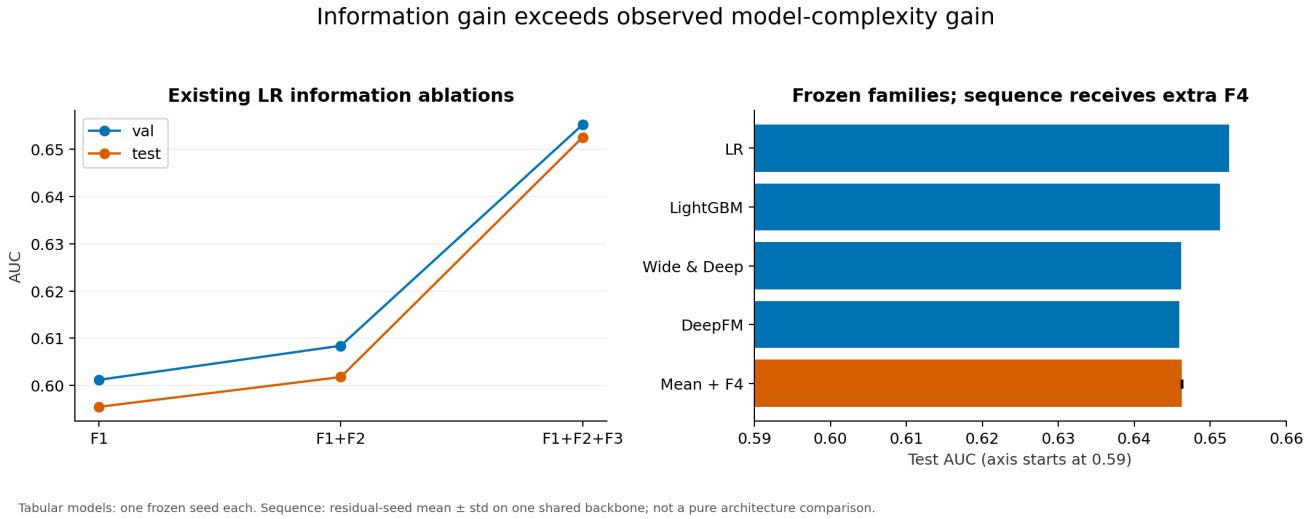


图 1 | 已有 LR 信息层对照与冻结模型。右图横轴起点 0.59；序列增加 F4，不是纯架构对照。

F3 的 LR AUC 增量约 0.05070，F2 约 0.00630。原 LR 选择 epoch 分别为 3、3、2；不能解释为完全相同固定 epoch 的因果对照，也未新增 LR 对其他模型的显著性检验。来源：[R2、R3、R7]。

03 · 五组预先冻结比较

表 2 | 左模型减右模型。AUC 为正、LogLoss 为负代表左侧较好；secondary 仅为机制性 / 探索性比较。

顺序	冻结比较	ΔAUC	ΔLogLoss
Primary 1	Mean matched − zero	+0.000330347	−0.000056164
Primary 2	Mean matched − mean mismatched	+0.000405708	−0.000030542
Secondary 3	Attention matched − zero	+0.000321725	−0.000058000
Secondary 4	Attention matched − attention mismatched	+0.000397302	−0.000032132
Secondary 5	Attention matched − Mean matched	−0.000008622	−0.000001836

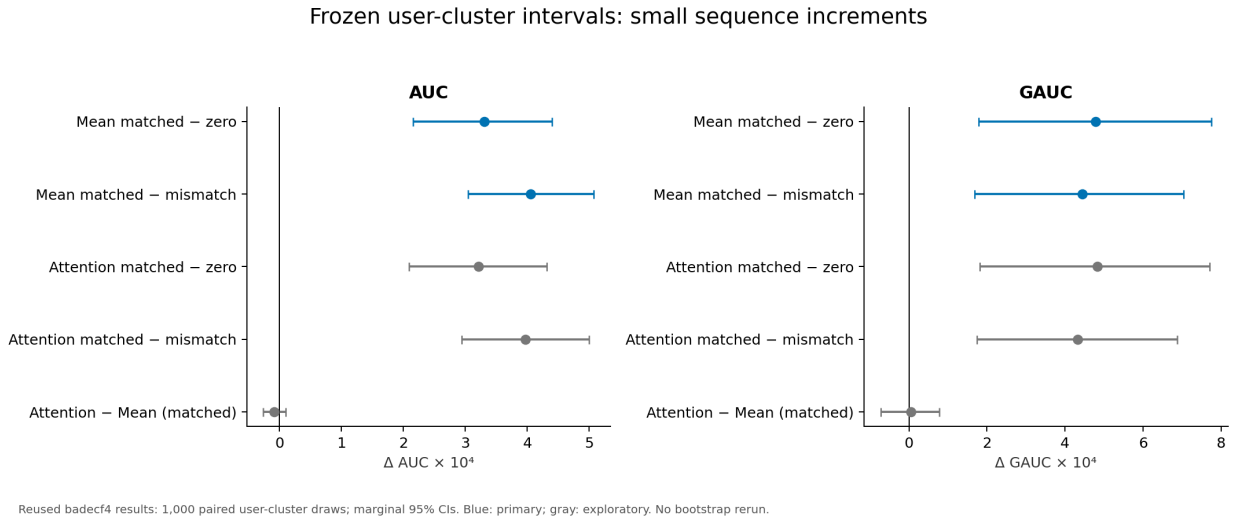


图 2 | 已有用户 cluster bootstrap 的 95% 边际区间；横轴效应乘以 10⁴。蓝色为 primary，灰色为探索性比较。

原 bootstrap seed=20260927，共 1,000 次有效重复；整用户曝光一起抽样。两个 primary 的 AUC/LogLoss 在联合四假设 Holm 下 p=0.003996。三个残差 seed 的 matched−mismatched 在四项指标上方向一致。区间是给定模型与日期的数据抽样不确定性，seed 标准差是固定 backbone 下的训练随机性；两者不同。来源：[R1、R2]。

04 · 增量很小，用户内排序与全局排序不同

Mean matched − zero 的 ΔAUC=+0.000330347，已有 95% CI 为 [+0.000215737, +0.000440027]。Mean matched − mismatched 的 ΔAUC=+0.000405708，已有 CI 为 [+0.000304701, +0.000507655]。它们分别约为 0.0330 和 0.0406 个 AUC 百分点；LogLoss 相对改善仅约 0.0291% 和 0.0158%。统计可检测不等于实际增益很大。

Attention − mean 的 AUC、PR-AUC、GAUC 区间含零；LogLoss 百分位区间略低于零，但预先定义的 centered p=0.064935。两种统计量并非互为反演，原样保留，不能择优引用。Mean 仍为主要序列模型。

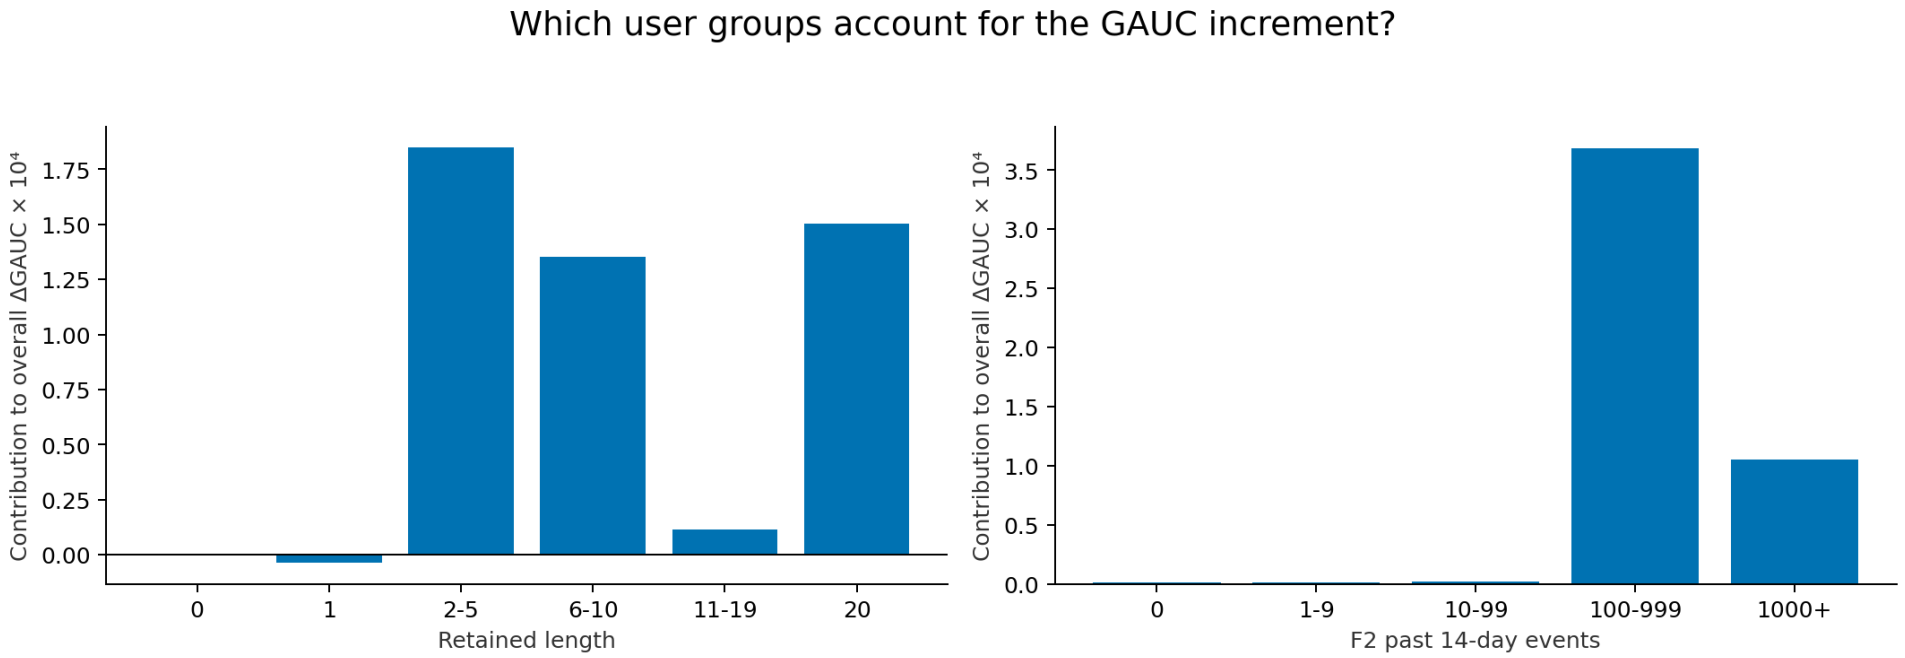


图 3 | Mean matched − zero 的 GAUC 加性贡献；各面板加总均为 +0.000478364。分组贡献包含组大小和组内效应。

约 98.89% 的 GAUC 增量来自已知用户；长度 2–5、6–10、20 贡献主要增益，长度 1 略为负，空历史严格为零。活跃度 100–999 和 1000+ 分别贡献约 77.02%、22.05%。但所有固定活跃度分桶的全局 AUC 仍是 LR 更高；这些是描述性分解，没有新增分组显著性检验。来源：[R1、R4]。

05 · 长历史：为何 AUC 改善而 LogLoss 恶化

在保留长度 20 的组中，Mean matched − mismatched 的 ΔAUC=+0.000474273，ΔLogLoss=+0.000019789。排序改善与概率误差变差可以同时成立：非点击样本增加的损失约 +0.000615，略超过点击样本改善的约 −0.000595。原始历史长度 ≥50 的样本贡献了净损失恶化的 58.64%。

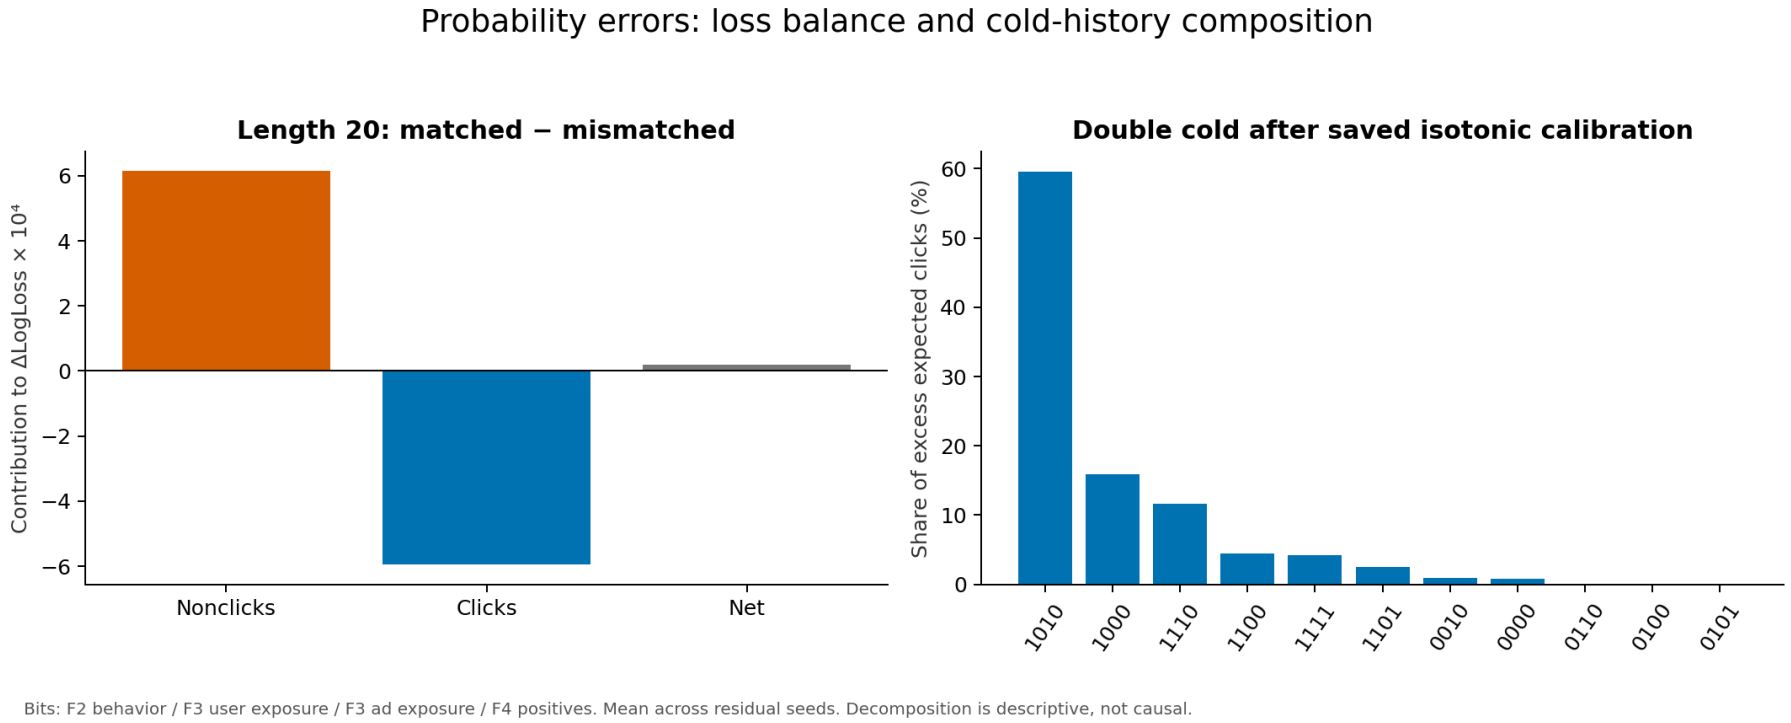


图 4 | 左：长度 20 组的标签分解，纵轴为 ΔLogLoss ×10⁴；右：校准后双冷启动过量预测点击的构成。

“20”表示达到截断上限，包含原始长度等于及大于 20。上述分解解释损失的加总关系，并不识别截断的因果效果；该组 matched 相对 zero 的 LogLoss 仍更好。

右图四位证据码依次表示：F2 行为、F3 用户曝光、F3 广告曝光、F4 正点击历史是否存在。1010 组贡献约 59.54% 的过量预测；0000 组只贡献约 0.82%。用户 / 广告不在 train 词表，仍可能具有随后积累的历史证据，“冷启动”不等于“完全空历史”。来源：[R4]。

06 · 全局校准改善，不代表冷启动偏差消失

校准只在 validation 拟合与选择：按 impression_id 哈希进行约 80% 拟合、20% 方法选择，再在完整 validation 重拟合所选方法。四个序列条件各三个 seed、zero 一次，共 13 个校准器，均选择 isotonic。完整 validation 上的校准后指标属于拟合内指标，不是独立验证。

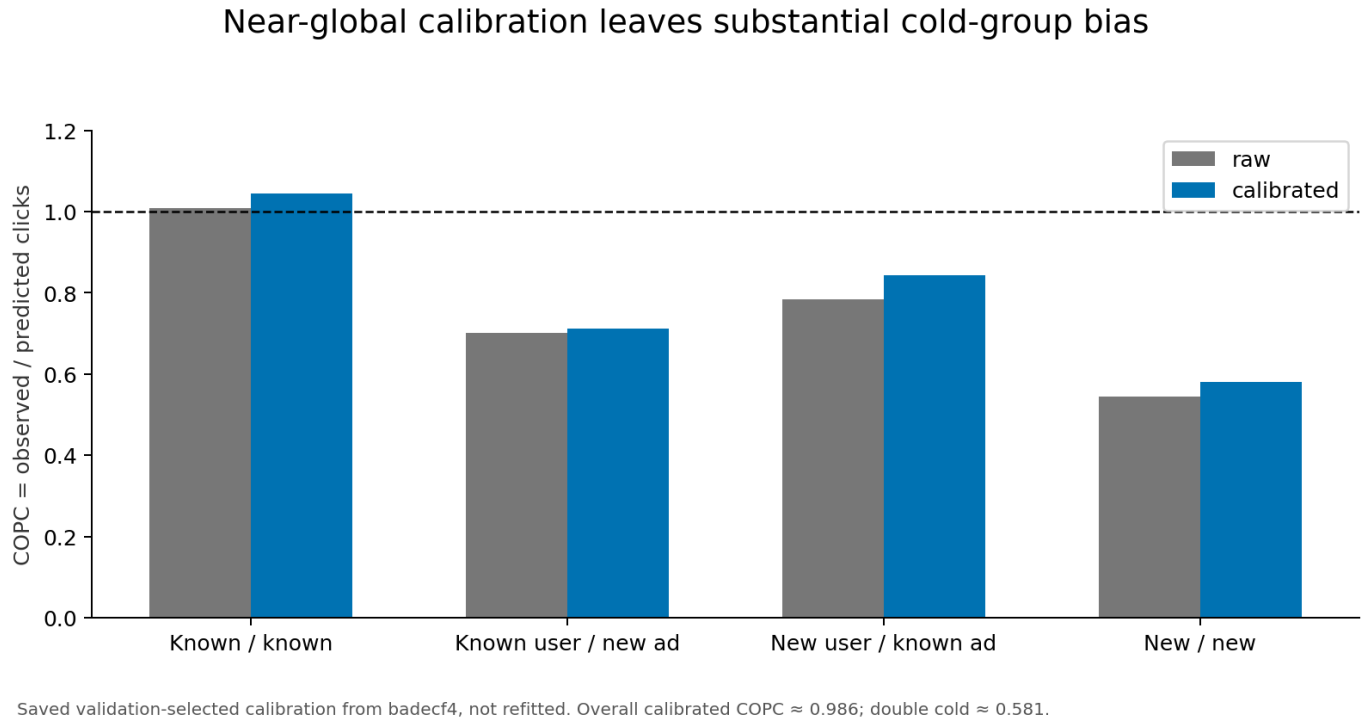


图 5 | 已有校准前后冷启动 COPC；虚线 1 为理想值，低于 1 表示高估。校准器与图表均直接复用冻结产物。

Mean matched 的 test 校准后 LogLoss=0.192839887、ECE=0.001043477、COPC=0.986346；双冷启动 COPC 却只有约 0.581043，对应 28,331 条曝光中 1,024 次点击，而预测约 1,762 次。已知用户 / 已知广告组 COPC 从约 1.009267 升到 1.043399，偏差方向与改善程度并不一致。

全部 13 个预测器的整体 LogLoss/ECE 改善，但 AUC、PR-AUC、GAUC 均下降；isotonic 引入的并列可改变排序指标。共享 evaluator 的 ECE 为 10 个等频箱；校准选择历史辅助输出采用 20 个等宽箱，不能混作同一指标口径。未使用 test 决定是否保留校准器。来源：[R1、R4]。

07 · 共同漏报与模型互补性的审计

五模型是 LR、LightGBM、Wide & Deep、DeepFM 和 Mean matched。在每个模型各自 top-10% 曝光预算下，71.38% 的真实点击被五者共同漏掉；分母为全部 test 点击，而不是全部曝光。使用 probability≥0.5 时，共同漏报约 99.97%，不能混用这两种操作策略。

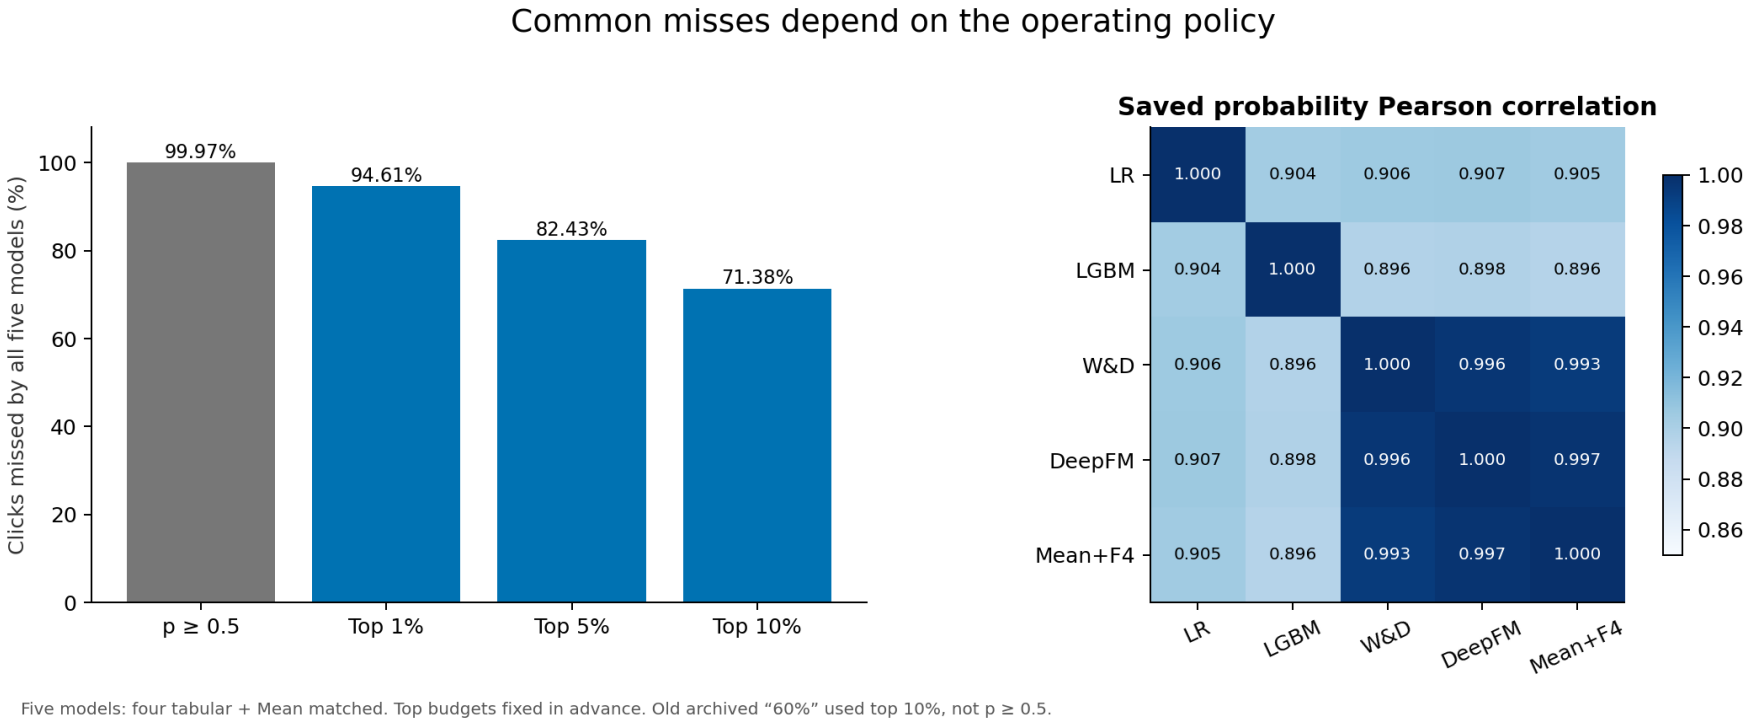


图 6 | 共同漏报随曝光预算变化；右图为已保存概率的 Pearson 相关。Top 10% 列对应每模型 top-10% 曝光预算下的 71.38% 共同漏报。

旧“60%”代码本来采用 top-10% 分位阈值，并非 probability≥0.5。旧预测数组缺失，且旧脚本会跳过缺失模型、缺少 ID 对齐断言，因此无法精确复现旧 60%；不能将其与重建后的 330.9 万 test 曝光结果合并。

每模型 top-10% 集合的并集覆盖 14.61% 曝光、召回 28.62% 点击，不是相同预算下的集成收益。Mean matched 与 DeepFM 的概率 Pearson 约 0.99734。使用真实标签逐行挑选最低损失的 oracle LogLoss 约 0.178235，是不可部署的乐观界，不是已实现的集成效果。来源：[R4、R8]。

08 · 冻结组件删除：敏感性诊断

D3 仅使用 05-12 validation。Frozen component deletion 明确属于 sensitivity diagnostic（敏感性诊断），不是 retrained ablation（重新训练的消融）。参数保持固定，特征中和或 logit 分支删除可能造成分布外输入；不能将剩余分支当作独立训练的模型。

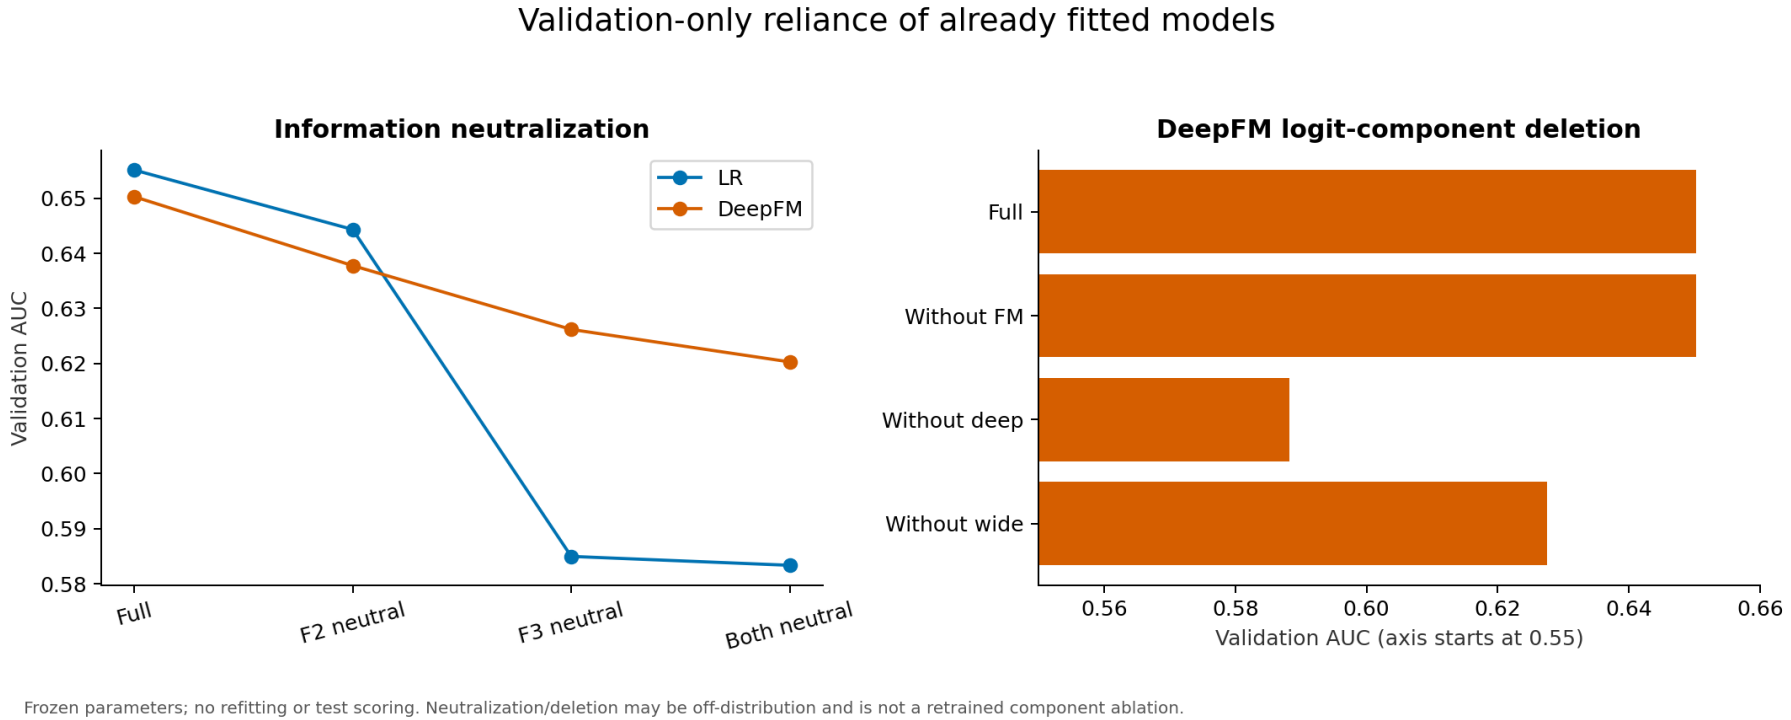


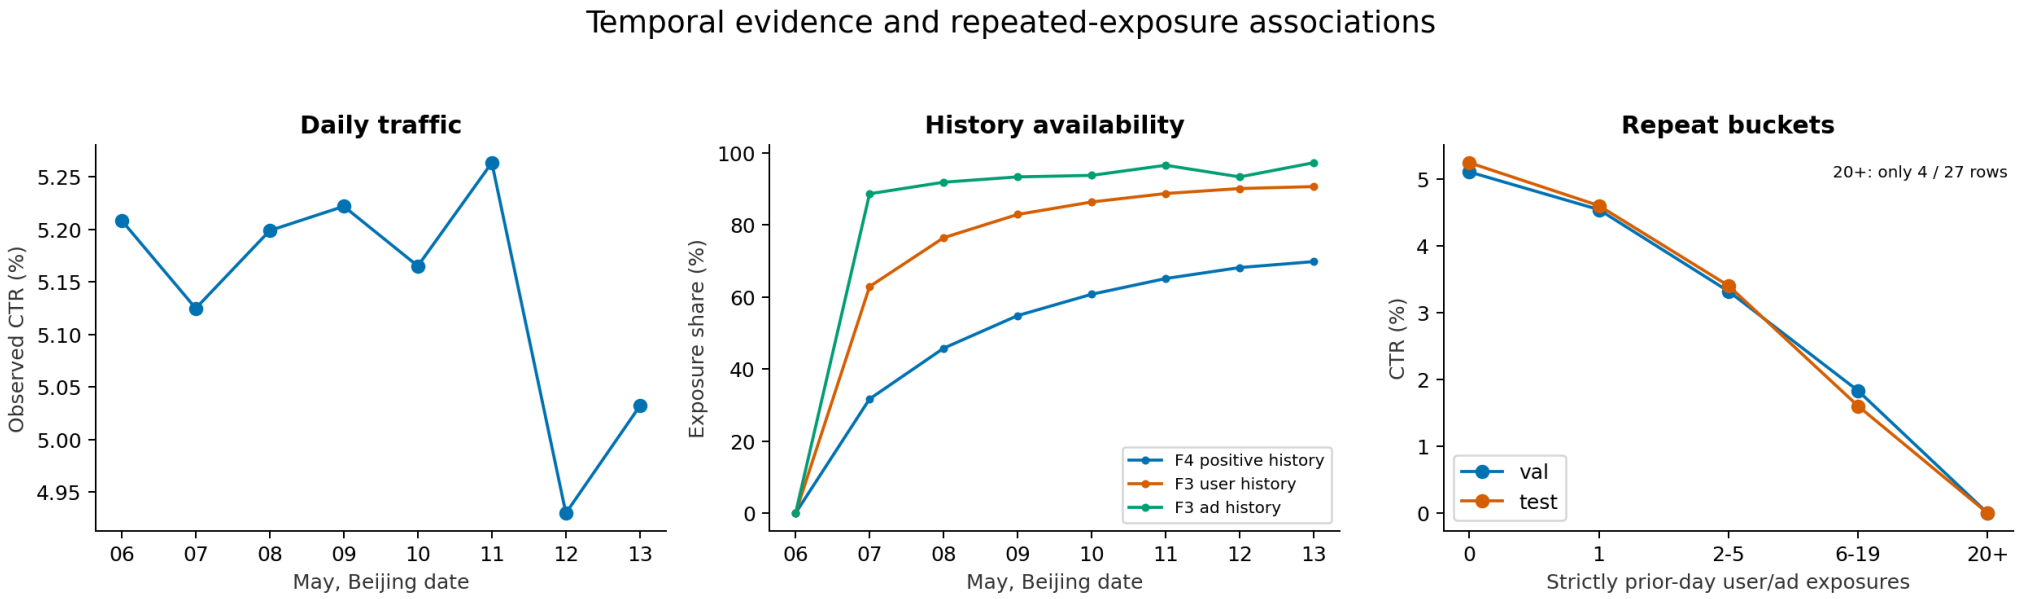
图 7 | Validation-only sensitivity diagnostic；左为冻结模型的 F2/F3 中和，右为冻结 DeepFM logit 分支删除，横轴起点 0.55。不是 retrained ablation。

LR 的 validation AUC：完整 0.655163，中和 F2 为 0.644353，中和 F3 为 0.584946；DeepFM 对应 0.650315、0.637786、0.626190。两者均更依赖已有 F3。

删除 DeepFM 的 FM 项后 AUC 仅从 0.650315 变为 0.650292，而 LogLoss 从 0.189813 变为 0.190702，说明排序与概率水平变化不能互相替代。LR 的 F2 加性项在同一 validation 日的同用户内恒定，因此删除 F2 可改变全局 AUC，而不改变用户内排序。现有 epoch 曲线记录过拟合迹象，但不能证明模型复杂度普遍有害。来源：[R5]。

09 · 时间漂移与重复曝光：描述性关联

时间漂移与重复曝光结果均为描述性关联，不是因果估计。05-11、05-12、05-13 的 CTR 分别为 5.2633%、4.9299%、5.0319%，变化并不单调。Validation 到 test 的新用户占比从约 9.94% 升至 11.70%，新广告从 6.71% 升至 8.77%。



Descriptive dates, not rolling-origin model evaluation. More history partly reflects window accumulation. Repeat association does not establish fatigue.

图 8 | 每日 CTR、历史证据覆盖与重复曝光 CTR。左中图横轴为北京时间 5 月日期；右图重复次数严格来自曝光日之前。

历史广告证据覆盖从 93.29% 升至 97.22%，部分来自可观测窗口累积。三日滚动表只描述流量，并未执行 rolling-origin 模型评估，也没有把训练期预测当成 held-out 预测。

test 的历史 user/ad 重复曝光桶 0、1、2–5、6–19 的 CTR 约为 5.24%、4.60%、3.40%、1.60%。≥20 桶只有 27 条曝光且无点击，AUC 不可定义。曝光选择、幸存者偏差与左截断均存在，因此不能把较低 CTR 直接解释为广告疲劳。只有两个 held-out 日期，不支持稳定的跨时期泛化定律。来源：[R6]。

10 · 结论层次与证据限制

问题	当前证据允许的结论	不允许的延伸
历史信息是否重要	LR 信息层结果与冻结敏感性均支持 F3 的主要贡献	不能声称对所有模型与数据均成立
matched 是否优于 mismatched	五组冻结比较中的匹配收益小且可统计检测	不能解释为完全控制所有热门度 / 活跃度混杂
序列是否超越 zero	对冻结 backbone 有小幅 AUC、LogLoss、GAUC 增益	不能声称三次独立 backbone 重训获胜
attention 是否超越 mean	无稳健实际优势；mean 仍为主要序列模型	不因 test 结果更换优先级
全局与用户内排序	LR 全局强；Mean matched 的 GAUC 较高	不新增未冻结的显著性比较
校准与分组误差	整体概率误差改善，但双冷启动偏差保留	不声称分组校准已被验证有效

Test 在早期基线开发中已经被查看，后来才冻结，不是从未触碰的 holdout。bootstrap 与深挖方案是在已知整体 test 结果后、对应新分组结果前固定，不能追称为最初预注册。校准实际采用 impression-level 80/20，而非历史提案的 user-grouped OOF，偏离须保留。

各表格模型只有一个 seed；三个序列 seed 只刻画共享冻结 backbone 下的残差随机性。未完成 LightGBM F1/F12、独立训练 FM/DNN 消融、三套独立表格 backbone 或公平独立吞吐基准。已有混合批量推理时间不能冒充各模型独立速度比较。

冻结证据仍为 badecf4 及 DIN_F4_TEST_RESULTS.md。所有新增交付仅为已有数字的核验与呈现，不增加训练、推理、统计检验或 post-hoc 分析。来源：[R1、R7]。

11 · 复现入口与仓库内引用

从仓库根目录执行只读交付检查：python src/37_verify_frozen_delivery.py；python src/38_release_audit.py。完整合成数据测试：python -m unittest discover -s tests -v；格式检查：git diff --check。这些不是重跑实验的命令。

核心依赖与已测版本分别见 requirements.txt、requirements-tested.txt；图表环境见 requirements-plot.txt；中文 PDF 排版环境见 requirements-report.txt。PDF 排版与 CTR 环境隔离。生成命令、字体参数及数据目录说明见 docs/RELEASE_AUDIT.md。

引用	仓库内可定位证据（路径相对仓库根目录）
[R1]	docs/DIN_F4_TEST_RESULTS.md；results/sequence_posthoc_v1/
[R2]	results/sequence_selection_v2/；results/sequence_test_v2/
[R3]	results/lr_f1*/；results/lightgbm_f1_f2_f3/；results/wide_deep_f1_f2_f3/；results/deepfm_f1_f2_f3/
[R4]	docs/DEEP_DIVE_D2_RESULTS.md；results/deep_dive_d2_v1/
[R5]	docs/DEEP_DIVE_D3_RESULTS.md；results/deep_dive_d3_v1/
[R6]	docs/DEEP_DIVE_D4_RESULTS.md；results/deep_dive_d4_v1/
[R7]	docs/FINAL_REPORT.md；docs/DEEP_DIVE_RESEARCH_PLAN.md
[R8]	results/deep_dive_final_v1/legacy_notebook_corroboration.json；archive/v1-original 分支

图 1–8 来自 figures/deep_dive_v1/ 已有八幅图（按本报告叙事重排），来源哈希见 results/deep_dive_final_v1/figure_manifest.json。图内沿用英文变量名，中文图题说明分母、方向和解释边界，未重绘或修改实验数值。

大型原始数据、模型、预测与中间表保存在本地 Git-ignored 目录，没有被小型 manifest 备份。缺少这些本地产物时只能核对已提交的汇总，不能声称完整重现实验。最终审计、逐页检查与测试日志位于 results/release_audit_v1/。项目在本次 release 后停止扩展。